

关于信息论在变分自编码器中应用的研究综述

周韧平 清华大学 计算机系

2025 年 5 月 7 日

1 引言

变分自编码器 (Variational Autoencoder, VAE) 作为一种强大的生成模型，在深度学习和机器学习领域中扮演着重要的角色。自其首次被提出以来，VAE 在图像生成、文本生成、音频生成等多个领域取得了显著的成果。然而，随着研究的不断深入，VAE 在表示学习、生成质量和模型泛化能力等方面仍面临诸多挑战。为了进一步提升 VAE 的性能，研究者们开始从信息论的角度探索新的解决方案，以优化潜在表示、提高生成质量和增强模型的泛化能力。

信息论为 VAE 的研究提供了丰富的理论基础和工具。通过引入熵、互信息和 KL 散度等概念，研究者们能够更深入地理解 VAE 的训练过程和生成机制。这些信息论工具不仅帮助揭示了 VAE 的内在机制，还为改进模型架构和训练方法提供了新的思路。例如，信息瓶颈理论 (Information Bottleneck, IB) 通过优化潜在变量与输入数据之间的互信息，实现了更解耦的表示，从而提高了生成质量和模型的泛化能力。此外，基于 KL 散度的优化方法也在提升 VAE 的训练稳定性和生成质量方面发挥了重要作用。

尽管如此，VAE 在处理复杂数据分布、训练过程中的稳定性以及多模态数据建模等方面仍存在一些局限性。例如，传统的 VAE 假设潜在变量的分布是高斯分布，这在处理多模态数据时可能无法有效捕捉数据的真实分布，导致生成样本缺乏多样性。此外，训练过程中的稳定性问题也可能影响模型的收敛速度和最终性能。为了克服这些挑战，研究者们正在探索新的模型架构、训练策略和优化方法，以进一步提升 VAE 的性能。

本文旨在综述信息论在变分自编码器中的应用，探讨其在提升生成质量、优化训练过程和拓展应用场景方面的最新进展。我们将首先介绍信息论的基础概念，包括熵、互信息和 KL 散度，并

分析这些概念在 VAE 中的应用。随后，我们将详细探讨基于互信息和信息瓶颈理论的改进方法，以及针对 KL 散度的优化策略。此外，我们还将讨论信息论在离散变分自编码器中的应用，并分析当前研究中面临的挑战与局限性。最后，我们将展望 VAE 的未来发展方向，探讨技术创新、应用拓展以及社会和伦理影响等方面的研究趋势。

通过本文的综述，我们希望为研究者提供一个全面的视角，以更好地理解信息论在 VAE 中的应用，并为未来的研究提供有价值的参考。

2 信息论基础

2.1 熵与信息量

信息量是衡量一个事件发生时所携带的信息多少的指标。根据香农的定义，信息量 $I(x)$ 与事件发生的概率 $p(x)$ 成反比，具体公式为： $I(x) = -\log p(x)$ 。其中，对数的底数通常为 2，此时信息量的单位是比特 (bits)。这个定义符合直觉：罕见事件的发生比常见事件更具信息量。

熵 [1-2] 是信息论中的核心概念，用于衡量一个随机变量的不确定程度。它是随机变量所有可能取值的信息量的期望值。对于离散随机变量 X ，其熵 $H(X)$ 定义为： $H(X) = -\sum_i p(x_i) \log p(x_i)$ 其中， $p(x_i)$ 是随机变量 X 取值为 x_i 的概率。熵的性质包括：

- **非负性**：熵总是非负的，即 $H(X) \geq 0$ 。
- **最大值**：当所有事件等概率发生时，熵达到最大值 $\log n$ ，其中 n 是事件的总数。

熵是多个事件信息量的加权平均值，权重是各事件的概率。换句话说，熵反映了整体系统的平均信息量或不确定性。

2.2 互信息

互信息 [1-2] 是信息论中的另一个重要概念，用于衡量两个随机变量之间的相互依赖程度。它

量化了知道一个随机变量的信息后, 对另一个随机变量不确定性的减少量。互信息的定义如下:

对于两个随机变量 X 和 Y , 其互信息 $I(X;Y)$ 定义为: $I(X;Y) = \sum_{x \in X} \sum_{y \in Y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)}$, 其中 $p(x,y)$ 是 X 和 Y 的联合概率分布。 $p(x)$ 和 $p(y)$ 分别是 X 和 Y 的边缘概率分布。

互信息也可以用熵来表示: $I(X;Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$ 。其中: $H(X)$ 和 $H(Y)$ 分别是 X 和 Y 的熵。 $H(X|Y)$ 和 $H(Y|X)$ 分别是 X 给定 Y 和 Y 给定 X 的条件熵。

互信息的性质有:

- **非负性:** 互信息总是非负的, 即 $I(X;Y) \geq 0$ 。当且仅当 X 和 Y 独立时, 互信息为零。
- **对称性:** 互信息是对称的, 即 $I(X;Y) = I(Y;X)$ 。
- **最大值:** 当 X 和 Y 完全相关时, 互信息达到最大值, 即 $I(X;Y) = H(X) = H(Y)$ 。

2.3 Kullback-Leibler 散度 (KL 散度)

KL 散度 (Kullback-Leibler Divergence) [3], 也称为相对熵, 是信息论中用于衡量两个概率分布之间差异的量度。它反映了从一个概率分布到另一个概率分布的信息损失或“距离”。对于两个离散概率分布 P 和 Q , KL 散度定义为: $D_{KL}(P||Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$, 对于连续概率分布, KL 散度定义为: $D_{KL}(P||Q) = \int_{-\infty}^{\infty} p(x) \log \frac{p(x)}{q(x)} dx$ 其中: $P(x)$ 和 $Q(x)$ 分别是概率分布 P 和 Q 在点 x 的概率密度。 $\log$ 通常以 2 为底, 此时 KL 散度的单位是比特; 也可以用自然对数 $\ln$, 此时单位是纳特 (nats)。KL 散度的性质有:

- **非负性:** KL 散度总是非负的, 即 $D_{KL}(P||Q) \geq 0$ 。当且仅当 $P(x) = Q(x)$ 时, KL 散度为零。
- **不对称性:** KL 散度不是对称的, 即 $D_{KL}(P||Q) \neq D_{KL}(Q||P)$ 。因此, 它不是一个真正的距离度量。

3 变分自编码器概述

3.1 基本架构

变分自编码器 (VAE) [4] 是一种生成模型, 结合了深度学习和贝叶斯推断的思想。它旨在通过学习数据的低维潜在表示 (latent representation)




图1 变分自编码器 (VAE) 基本结构

来生成新的数据样本。与传统的自编码器 (Autoencoder) 不同, VAE 不仅能够学习数据的压缩表示, 还能通过概率分布生成新的数据。

如图1所示, VAE 的架构由两部分组成: 编码器 (Encoder) 和解码器 (Decoder)。

- **编码器:** 将输入数据 x 映射到潜在空间的参数分布 (通常是均值和方差)。具体来说, 编码器输出两个向量: 均值向量 μ 和方差向量 σ^2 。
- **解码器:** 从潜在空间中采样一个点 z , 并将其映射回数据空间, 生成重构数据 $\hat{x}$ 。

为了使 VAE 能够通过梯度下降进行训练, 需要解决从概率分布中采样的不可导问题。重参数化技巧 [5] 通过引入一个独立的标准正态分布 $\epsilon \sim \mathcal{N}(0, I)$, 将采样过程表示为:

$$z = \mu + \sigma \odot \epsilon$$

其中 $\odot$ 表示逐元素乘法。这样, 采样过程变为可导的, 可以计算梯度。

3.2 损失函数

VAE 的训练目标是最小化以下损失函数:

$$\mathcal{L} = \mathcal{L}_{\text{recon}} + \mathcal{L}_{\text{KL}}$$

- **重构误差 (Reconstruction Loss):** 衡量解码器生成的重构数据 $\hat{x}$ 与原始数据 x 之间的差异。通常使用均方误差 (MSE) 或交叉熵损失。

$$\mathcal{L}_{\text{recon}} = \mathbb{E}_{z \sim q(z|x)} [-\log p(x|z)]$$

- **KL 散度 (Kullback-Leibler Divergence):** 正则化潜在空间的分布, 使其接近先验分布 (通常是标准正态分布)。KL 散度项确保潜在变量 z 的分布 $q(z|x)$ 接近先验分布 $p(z)$ 。

$$\mathcal{L}_{\text{KL}} = D_{KL}(q(z|x)||p(z))$$

论文 [4] 中针对损失函数的设计给出了详细证明, 对于样本 $x^{(i)}$, 其边际分布可以写作

$$\log p_{\theta}(x^{(i)}) = D_{KL}(q_{\phi}(z|x^{(i)})||p_{\theta}(z|x^{(i)})) + \mathcal{L}(\theta, \phi; x^{(i)})$$

其中 θ 和 ϕ 分别表示真实参数和编码器学到的参数，右式第一项表示真实先验分布与编码器学到的分布差异，为一个非负值。第二项为负的数据证据最小下界（Evidence Lower Bound, ELBO），其公式为：

$$\begin{aligned}\mathcal{L}(\theta, \phi; x^{(i)}) &= -D_{KL}(q_{\phi}(z|x^{(i)})||p_{\theta}(z)) \\ &\quad + \mathbb{E}_{q_{\phi}(z|x^{(i)})}[\log p_{\theta}(x^{(i)}|z)] \\ &= -(\mathcal{L}_{KL} + \mathcal{L}_{recon})\end{aligned}$$

这样最大化联合概率分布问题就转化成了最小化 $\mathcal{L}_{KL} + \mathcal{L}_{recon}$ 。

3.3 训练过程

- **前向传播**：输入数据 x 通过编码器，得到均值 μ 和方差 σ^2 。使用重参数化技巧从潜在分布 $q(z|x)$ 中采样 z 。将 z 输入解码器，生成重构数据 $\hat{x}$ 。
- **计算损失**：计算重构误差 $\mathcal{L}_{recon}$ ，KL 散度 $\mathcal{L}_{KL}$ ，二者相加得到总损失。
- **反向传播**：通过梯度下降优化网络参数，最小化总损失 $\mathcal{L}$ 。

4 信息论在变分自编码器中的应用

4.1 基于互信息和信息瓶颈理论的改进

基于互信息理论对变分自编码器（VAE）的改进主要集中在如何通过优化互信息来增强 VAE 的表示学习能力，提高解耦性、生成质量和泛化能力。这类工作的核心思想是通过最大化 $I(Z; X)$ ，使得潜在变量 Z 更好地捕捉输入数据 X 的关键特征，让生成的样本更接近真实数据分布。VMI-VAE [6] 提出了一种变分互信息最大化框架，用于增强 VAE 中潜在变量与观测数据之间的互信息。另一篇工作 Mu-VAE [7] 专注于文本生成中的 VAE 问题，提出了一种通过最大化输入和潜在变量之间的互信息来改善潜在变量缺乏信息的问题。

信息瓶颈（Information Bottleneck, IB）[8-10] 理论是一种基于互信息的方法，旨在通过压缩输入数据 X 的信息，同时保留与目标变量 Y 最相关的部分，从而提高模型的泛化能力。其核心思想是通过一个潜在变量 Z 来平衡输入数据 X 和目标变量 Y 之间的信息流动，优化目标可以表示为：

$$\mathcal{L}_{IB} = I(Z; Y) - \lambda I(Z; X)$$

其中， $I(Z; Y)$ 表示 Z 与目标变量 Y 之间的互信息， $I(Z; X)$ 表示 Z 与输入数据 X 之间的互信息，而 λ 是一个超参数，用于控制压缩程度。

VIB [11] 是信息瓶颈理论的一种变体，通过变分推断来近似互信息的优化。VIB 的损失函数可以表示为：

$$\mathcal{L}_{VIB} = -\mathbb{E}_{z \sim q(z|x)} [\log p(y|z)] + \beta I(Z; X)$$

在 VAE 的无监督学习场景中，可以将 Y 视为输入数据 X 本身，从而将 VAE 看作 VIB 的一个特例。研究 [12] 发现，在训练时通过引入可调超参数 β ，可以控制信息压缩的程度，在 $\beta > 1$ 时，可以提高学习到的潜表征的非纠缠程度。引入超参数后的损失函数为：

$$\mathcal{L} = \mathcal{L}_{recon} + \beta \mathcal{L}_{KL}$$

在 β -VAE 的基础上，研究 [13] 基于信息瓶颈理论给出了进一步的分析解释，通过改进原有的训练机制，在训练过程中逐步增加潜在编码的信息容量，使模型能够更鲁棒地学习解耦表示，同时避免了之前在重构精度上的权衡。另一篇工作 [14] 针对解码器过于灵活时会忽略潜在变量的问题，提出了 Info-VAE 框架，通过引入新的训练目标来解决上述问题。新的目标函数为：

$$\begin{aligned}\mathcal{L}_{Info} &= -\lambda D_{KL}(q_{\phi}(z)||p(z)) \\ &\quad - \mathbb{E}_{q(z)}[D_{KL}(q_{\phi}(x|z)||p_{\theta}(x|z))] \\ &\quad + \alpha I_q(x; z)\end{aligned}$$

其中： λ 是一个缩放参数，用于增加 $q_{\phi}(z)$ 和 $p(z)$ 之间的散度权重，从而平衡 X 和 Z 之间的不平衡。 α 是一个超参数，用于控制互信息 $I_q(x; z)$ 的权重。 $I_q(x; z)$ 是在分布 $q_{\phi}(x, z)$ 下 x 和 z 之间的互信息。当 $\alpha = 0$ 和 $\lambda = 1$ 时，InfoVAE 退化为原始的 ELBO 损失函数。当 $\lambda > 0$ 自由选择，且 $\alpha + \lambda - 1 = 0$ 时，使用 D_{KL} 散度，InfoVAE 退化为 β -VAE 模型。

4.2 KL 散度的优化与调整

在变分自编码器（VAE）中，KL 散度用于正则化潜在空间的分布，使其接近先验分布。研究 [13, 15-16] 表明，通过在训练中逐步增加 KL 散度的权重，从而实现更鲁棒的解耦表示和更好的重构精度。

由于 KL 散度存在非对称性，对零概率不敏感等问题，一些研究尝试针对 VAE 中的 KL 散度

进行研究改进。Info-VAE 中, 当 $\alpha = 1$, $\lambda = 1$, 且 D 选择为 Jensen-Shannon 散度时, InfoVAE 退化为对抗自编码器 [17] (AAE)。另一项研究 [18] 通过理论分析和实验证明了用 Wasserstein distance 代替 KL 散度具有更好的理论近似性和更高效的收敛性。

4.3 信息论在离散变分自编码器中的应用

VQ-VAE (Vector Quantized Variational Autoencoder) [19] 是一种结合了矢量量化 (Vector Quantization) 和变分自编码器 (Variational Autoencoder, VAE) 的生成模型。它旨在通过离散化的潜在表示来捕捉数据的结构化特征, 同时保持生成模型的高效性和灵活性。VQ-VAE 由 DeepMind 在 2017 年提出, 其核心思想是将连续的潜在空间离散化, 从而生成更具有结构化的表示。如图 2 所示, 和连续建模的 VAE 相比, VQ-VAE 包含一组离散的向量, 每个向量称为一个“码字” (code word)。编码器的输出 z 被量化为码本中最接近的码字。




图 2 VQ-VAE 流程图示

信息论在离散变分自编码器 (Discrete Variational Autoencoder, DVAE) 中的应用是一个活跃的研究领域。与连续变量的 VAE 相比, 离散变量的 VAE 在表示学习和生成任务中具有独特的优势, 但也存在表征能力不足, 重建效果不如连续建模 VAE 的问题。

针对 VQ-VAE, 研究 [20-21] 发现, VQ-VAE 通过限制编码比特率, 实现了信息瓶颈原则, 能够以无监督的方式提取数据的有意义潜在表示。这些工作通过增加代码本学习率、在量化前启用批量归一化以及周期性批量代码本重估计等方法来稳定训练过程。

5 当前研究的挑战与局限性

变分自编码器 (VAE) 在表示学习和生成任务中虽然取得了显著的成果, 但仍存在一些挑战与局限性。这些挑战主要集中在如何更有效地利用信息论的概念来优化潜在表示、提高生成质量和模型的泛化能力。

5.1 KL 散度权重的平衡问题

VAE 的损失函数由两部分组成: 重构误差和 KL 散度。如何在训练过程中平衡这两者是一个关键问题。如果重构误差过大, 生成的数据质量会下降; 而如果 KL 散度权重过高, VAE 的潜在变量 $q_\phi(z|x)$ 的概率质量会推得离先验分布太远, 导致模型完全忽略潜在变量, 仅依赖解码器生成数据, 导致“后验坍塌”。从信息论的角度来看, 后验坍塌意味着潜在变量 Z 与输入数据 X 之间的互信息 $I(Z; X)$ 过低, 导致潜在变量无法有效捕捉输入数据的关键信息。重构误差和 KL 散度分别对应于数据的保真度和潜在变量的正则化。平衡这两者需要在信息保留和信息压缩之间找到一个合适的权衡。

5.2 复杂数据分布的建模

在 VAE 中, KL 散度的计算通常假设潜在变量的分布是高斯分布。然而, 这种假设可能不适用于所有数据分布。如果无法有效建模复杂数据分布, 模型可能无法生成高质量的样本, 从而影响模型的泛化能力。

许多真实世界的的数据分布是多模态的, 即数据可以来自多个不同的分布。高斯分布假设在这种情况下可能无法有效建模, 导致生成的样本缺乏多样性。此外, 一些数据分布可能具有非高斯特性, 如尖峰、重尾等。高斯分布假设在这种情况下可能无法有效捕捉数据的真实分布, 导致生成的样本质量下降。针对更复杂的数据分布, 一些研究 [22-25] 提出了新的建模方法, 包括多尺度建模, 使用混合高斯模型等。

5.3 训练过程中的稳定性问题

VAE 的训练过程可能不稳定, 尤其是在使用复杂的编码器/解码器架构时, 研究 [26] 认为这种不稳定性源于对编码正态分布方差的解释不足。此外, 训练过程中的稳定性问题也可能与潜在变量的分布假设和优化目标有关。如果训练过程不稳定, 模型可能无法收敛到最优解, 从而影响生成质量和模型的泛化能力。

6 未来发展方向

6.1 技术创新与优化

6.1.1 架构改进

在模型架构上, 人们尝试引入更复杂的网络结构, 例如深度卷积网络、残差网络以及注意力机制等。这些先进的架构能够更好地捕捉数据中

的层次化特征和复杂模式，从而提高生成样本的细节和质量。例如，深度卷积网络可以有效地处理图像数据中的局部和全局信息，而注意力机制则可以帮助模型聚焦于数据中的关键部分，从而生成更符合人类视觉感知的样本。

6.1.2 损失函数优化

通过修改损失函数来解决模型训练中的一些问题，如“过度平滑”现象，从而生成更加多样化且高质量的数据。例如，通过引入更复杂的正则化项，如基于信息瓶颈理论的互信息正则化，可以促使模型学习到更具解耦性和可解释性的潜在表示，从而提高生成样本的质量。同时，动态调整训练过程中的超参数，如学习率和 KL 散度的权重，可以进一步优化模型的训练效果，使其在不同的训练阶段都能保持良好的学习性能。

6.1.3 训练过程改进

探索新的训练策略，比如使用对抗训练方法来提升 VAE 的性能，或者采用动态调整的学习率以优化训练过程，使模型更快收敛且更稳定。此外，还可以研究如何更有效地初始化模型参数，以及如何设计更合适的优化算法

6.2 应用拓展

6.2.1 可控生成

对生成过程的精细控制是提升生成质量和拓展应用场景的一个重要途径。这涉及到对潜在空间的深入理解和操作，例如通过设计更合理的潜在变量分布和采样策略，可以生成更具多样性和创造性的样本。同时，结合条件生成技术，如条件变分自编码器 (CVAE) [27]，可以在生成过程中引入额外的条件信息，从而实现对生成样本的更精确控制，使其更符合特定的需求和场景。

6.2.2 多模态拓展

目前，VAE 的应用主要局限在图像和文本领域，并且只能用于单一模态，将 VAE 与其他机器学习技术（如强化学习、生成对抗网络）结合，克服单一模型的局限性，可以有效拓展其应用场景。研究 VAE 在多模态数据（如文本-图像、语音-文本等）上的建模能力，推动跨模态生成与理解的发展，是当下研究的热点。通过学习不同模态数据之间的联合表示，模型可以完成更丰富的生成任务，实现更深入的模态间交互。随着视频生成模型的发展，将时序信息引入 VAE 压缩也成为了当下的热点研究话题。在视频生成领域，如 Allegro 的 VideoVAE [28]，Open-Sora [29] 等，搭建视频

级的 VAE 模型是构建一个好的视频生成模型的基石。在这一领域，未来的发展方向包括平衡重建质量和计算效率、改进潜在特征提取、增加潜在通道大小以及改善线性语义重建能力等。此外，还可以探索如何将 VAE 与其他视频处理技术结合，以实现更高质量的视频生成

6.2.3 社会和伦理影响

随着 VAE 在数据生成和处理方面的应用扩展，如何保护个人隐私和数据安全成为一个重要议题。未来的研究需要在提升模型性能的同时，确保数据处理的透明度和安全性。此外，自动生成的内容可能会被用于不正当用途，因此，研究社区和相关利益方需共同努力，确保技术的负责任使用，并制定相应的伦理指导原则。

7 总结

本文综述了信息论在变分自编码器 (VAE) 中的应用，探讨了其在提升生成质量、优化训练过程和拓展应用场景方面的最新进展。信息论中的核心概念，如熵、互信息和 KL 散度，为 VAE 的研究提供了丰富的理论基础和工具。通过引入这些信息论工具，研究者们能够更深入地理解 VAE 的训练过程和生成机制，并提出了多种改进方法。

在提升生成质量方面，基于互信息和信息瓶颈理论的改进方法通过优化潜在变量与输入数据之间的信息流动，实现了更解耦的表示，从而提高了生成样本的质量和多样性。此外，针对 KL 散度的优化策略也在提升训练稳定性和生成质量方面发挥了重要作用。这些方法通过调整 KL 散度的权重和优化潜在空间的分布，有效地解决了训练过程中的稳定性问题，并提高了模型的泛化能力。

在拓展应用场景方面，信息论工具为 VAE 在多模态数据建模和复杂数据分布处理中的应用提供了新的思路。通过引入混合高斯分布、非高斯分布和多尺度建模方法，VAE 能够更有效地捕捉复杂数据分布的特性，从而在图像生成、文本生成和视频生成等多个领域取得了显著的成果。此外，研究者们还探索了 VAE 在社会和伦理影响方面的应用，强调了在提升模型性能的同时，确保数据处理的透明度和安全性的重要性。

尽管 VAE 在信息论的指导下取得了显著进展，但仍面临一些挑战和局限性。例如，复杂的编码器/解码器架构可能导致训练过程不稳定，而传统的高斯分布假设可能无法有效建模多模态数

据。为了克服这些挑战,未来的研究方向包括进一步优化模型架构、改进训练策略和探索新的信息论工具。此外,随着 VAE 在更多领域的应用,如何确保技术的负责任使用并制定相应的伦理指导原则也将成为重要的研究方向。

综上所述,信息论在 VAE 中的应用不仅为提升生成质量和优化训练过程提供了新的视角,还为拓展应用场景和解决实际问题提供了有力的工具。未来,随着研究的不断深入和技术的持续进步,VAE 有望在更多领域发挥重要作用,为人工智能的发展做出更大贡献。

参考文献 (References)

- [1] C. E. Shannon. A mathematical theory of communication. *SIGMOBILE Mob. Comput. Commun. Rev.*, 5(1):3–55, January 2001.
- [2] Thomas M. Cover and Joy A. Thomas. *Elements of Information Theory (Wiley Series in Telecommunications and Signal Processing)*. Wiley-Interscience, USA, 2006.
- [3] Solomon Kullback and Richard A Leibler. On information and sufficiency. *The annals of mathematical statistics*, 22(1):79–86, 1951.
- [4] Diederik P Kingma, Max Welling, et al. Auto-encoding variational bayes, 2013.
- [5] Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. Stochastic backpropagation and approximate inference in deep generative models. In *International conference on machine learning*, pages 1278–1286. PMLR, 2014.
- [6] Andriy Serdega and Dae-Shik Kim. Vmi-vae: Variational mutual information maximization framework for vae with discrete and continuous priors. *arXiv preprint arXiv:2005.13953*, 2020.
- [7] Dayiheng Liu, Yang Xue, Feng He, Yuanyuan Chen, and Jiancheng Lv. μ -forcing: Training variational recurrent autoencoders for text generation. *ACM Transactions on Asian and Low-Resource Language Information Processing (TALLIP)*, 19(1):1–17, 2019.
- [8] Naftali Tishby, Fernando C Pereira, and William Bialek. The information bottleneck method. *arXiv preprint physics/0004057*, 2000.
- [9] Gal Chechik, Amir Globerson, Naftali Tishby, and Yair Weiss. Information bottleneck for gaussian variables. *Advances in Neural Information Processing Systems*, 16, 2003.
- [10] Naftali Tishby and Noga Zaslavsky. Deep learning and the information bottleneck principle. In *2015 IEEE information theory workshop (itw)*, pages 1–5. Ieee, 2015.
- [11] Alexander A Alemi, Ian Fischer, Joshua V Dillon, and Kevin Murphy. Deep variational information bottleneck. *arXiv preprint arXiv:1612.00410*, 2016.
- [12] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-vae: Learning basic visual concepts with a constrained variational framework. In *International conference on learning representations*, 2017.
- [13] Christopher P Burgess, Irina Higgins, Arka Pal, Loic Matthey, Nick Watters, Guillaume Desjardins, and Alexander Lerchner. Understanding disentangling in beta-vae. *arXiv preprint arXiv:1804.03599*, 2018.
- [14] Shengjia Zhao, Jiaming Song, and Stefano Ermon. Infvae: Information maximizing variational autoencoders. *arXiv preprint arXiv:1706.02262*, 2017.
- [15] Jianning Li, Jana Fragemann, Seyed-Ahmad Ahmadi, Jens Kleesiek, and Jan Egger. Training β -vae by aggregating a learned gaussian posterior with a decoupled decoder. In *MICCAI workshop on medical applications with disentanglements*, pages 70–92. Springer, 2022.
- [16] Huajie Shao, Yifei Yang, Haohong Lin, Longzhong Lin, Yizhuo Chen, Qinmin Yang, and Han Zhao. Rethinking controllable variational autoencoders. In *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19228–19237, 2022.
- [17] Alireza Makhzani, Jonathon Shlens, Navdeep Jaitly, Ian Goodfellow, and Brendan Frey. Adversarial autoencoders. *arXiv preprint arXiv:1511.05644*, 2015.
- [18] Zichuan Chen and Peng Liu. Towards efficient variational autoencoder using wasserstein distance. In *2022 IEEE International Conference on Image Processing (ICIP)*, pages 81–85. IEEE, 2022.
- [19] Aaron Van Den Oord, Oriol Vinyals, et al. Neural discrete representation learning. *Advances in neural information processing systems*, 30, 2017.
- [20] Adrian Łańcucki, Jan Chorowski, Guillaume Sanchez, Ricard Marxer, Nanxin Chen, Hans JGA Dolfing, Sameer Khurana, Tanel Alumäe, and Antoine Laurent. Robust training of vector quantized bottleneck models. In *2020 International Joint Conference on Neural Networks (IJCNN)*, pages 1–7. IEEE, 2020.
- [21] Hanwei Wu and Markus Flierl. Vector quantization-based regularization for autoencoders. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 6380–6387, 2020.
- [22] Alejandro Guerrero-López, Carlos Sevilla-Salcedo, Vanessa Gómez-Verdejo, and Pablo M Olmos. Multimodal hierarchical variational autoencoders with factor analysis latent space. *arXiv preprint arXiv:2207.09185*, 2022.
- [23] Qinyuan Luo, Jinglong Chen, Yanyang Zi, Yuanhong Chang, and Yong Feng. Multi-mode non-gaussian variational autoencoder network with missing sources for anomaly detection of complex electromechanical equipment. *ISA transactions*, 134:144–158, 2023.
- [24] Chunsheng Guo, Jialuo Zhou, Huahua Chen, Na Ying, Jianwu Zhang, and Di Zhou. Variational autoencoder with optimizing

- gaussian mixture model priors. *IEEE Access*, 8:43992–44005, 2020.
- [25] Junwen Bai, Shufeng Kong, and Carla P Gomes. Gaussian mixture variational autoencoder with contrastive learning for multi-label classification. In *international conference on machine learning*, pages 1383–1398. PMLR, 2022.
- [26] David Dehaene and Rémy Brossard. Re-parameterizing vaes for stability. *arXiv preprint arXiv:2106.13739*, 2021.
- [27] William Harvey, Saeid Naderiparizi, and Frank Wood. Conditional image generation by conditioning variational autoencoders. *arXiv preprint arXiv:2102.12037*, 2021.
- [28] Yuan Zhou, Qiuyue Wang, Yuxuan Cai, and Huan Yang. Allegro: Open the black box of commercial-level video generation model. *arXiv preprint arXiv:2410.15458*, 2024.
- [29] Bin Lin, Yunyang Ge, Xinhua Cheng, Zongjian Li, Bin Zhu, Shadong Wang, Xianyi He, Yang Ye, Shenghai Yuan, Liuhan Chen, et al. Open-sora plan: Open-source large video generation model. *arXiv preprint arXiv:2412.00131*, 2024.