

Pattern Recognition 2024: Homework 2

周韧平– `zrp21@mails.tsinghua.edu.cn`

September 21, 2024

Problem 1

(i) 首先计算似然函数，对于给定样本 $x_1, \dots, x_n$

$$\begin{aligned} L(\lambda) &= p(x_1 \cdots x_n | \lambda) \\ &= \prod_{i=1}^n p(x_i | \lambda) \end{aligned}$$

$$\begin{aligned} l(\lambda) &= \log(L(x)) \\ &= \sum_{i=1}^n \log(p(x_i | \lambda)) \\ &\propto \sum_{i=1}^n (x_i \log(\lambda) - \lambda) \end{aligned}$$

根据最大似然估计

$$\begin{aligned} \hat{\lambda} &= \operatorname{argmax}_{\lambda} l(\lambda) \\ &= \bar{x} \end{aligned}$$

(ii) 首先证明对于泊松分布 $X \sim P(\lambda)$ $E(X) = Var(X) = \lambda$

$$\begin{aligned} E(X) &= \sum_{x=0}^{\infty} (x \frac{\lambda^x e^{-\lambda}}{x!}) \\ &= \lambda \sum_{x=1}^{\infty} (\frac{\lambda^{x-1} e^{-\lambda}}{(x-1)!}) \\ &= \lambda \end{aligned}$$

$$\begin{aligned} E(X^2) &= \sum_{x=0}^{\infty} (x^2 \frac{\lambda^x e^{-\lambda}}{x!}) \\ &= \lambda^2 \sum_{x=2}^{\infty} (\frac{\lambda^{x-2} e^{-\lambda}}{(x-2)!}) + \lambda \sum_{x=1}^{\infty} (\frac{\lambda^{x-1} e^{-\lambda}}{(x-1)!}) \\ &= \lambda(\lambda + 1) \end{aligned}$$

$$\begin{aligned} Var(X) &= E(X^2) - E(X)^2 \\ &= \lambda \end{aligned}$$

对于 $\hat{\lambda} = \bar{x}$

$$\begin{aligned} E(\hat{\lambda}) &= \frac{\sum_{i=1}^n E(x_i)}{n} \\ &= \lambda \\ Var(\hat{\lambda}) &= Var(\bar{x}) \\ &= \frac{\lambda}{n} \end{aligned}$$

可以看出 $\hat{\lambda}$ 是对 λ 的无偏估计，且样本量越大，估计的有效性越强

Problem 2

(i)

$$\begin{aligned} l(\boldsymbol{\theta}) &= \sum_{i=1}^n \sum_{j=1}^d (x_i^j \log(\theta_j) + (1 - x_i^j) \log(1 - \theta_j)) \\ \frac{\partial l}{\partial \theta_j} &= \sum_{i=1}^n (\frac{x_i^j}{\theta_j} - \frac{1 - x_i^j}{1 - \theta_j}) \\ \frac{\partial l}{\partial \theta_j} = 0 &\implies \theta_j = \bar{x}^j, \frac{\partial^2 l}{\partial \theta_j^2} |_{\theta_j = \bar{x}^j} < 0 \end{aligned}$$

可以得到 $\hat{\theta} = \bar{x}$

(ii)

$$\begin{aligned}
 p(\theta|\mathcal{D}) &= \frac{p(\mathcal{D}|\theta)p(\theta)}{\int p(\mathcal{D}|\theta)p(\theta)d\theta} \\
 &= \frac{p(\mathcal{D}|\theta)}{\int p(\mathcal{D}|\theta)d\theta} \\
 &= \frac{\prod_{i=1}^d \theta_i^{n\bar{x}_i} (1 - \theta_i)^{n(1-\bar{x}_i)}}{\prod_{i=1}^d \int_0^1 \theta_i^{n\bar{x}_i} (1 - \theta_i)^{n(1-\bar{x}_i)} d\theta_i} \\
 &= \frac{\prod_{i=1}^d \theta_i^{n\bar{x}_i} (1 - \theta_i)^{n(1-\bar{x}_i)} (n+1)!}{\prod_{i=1}^d (n\bar{x}_i)! (n - n\bar{x}_i)!}
 \end{aligned}$$

(iii)

$$\begin{aligned}
 p(x|\mathcal{D}) &= \int p(x|\theta)p(\theta|\mathcal{D})d\theta \\
 &= \prod_{i=1}^d \int_0^1 \frac{\theta_i^{n\bar{x}_i} (1 - \theta_i)^{n(1-\bar{x}_i)} (n+1)!}{(n\bar{x}_i)! (n - n\bar{x}_i)!} \theta_i^{x_i} (1 - \theta_i)^{1-x_i} d\theta_i \\
 &= \prod_{i=1}^d \frac{(n\bar{x}_i + 1)^{x_i} (n + 1 - n\bar{x}_i)^{(1-x_i)}}{n + 2}
 \end{aligned}$$

(iv)

$$\hat{\theta}_i = \frac{n\bar{x}_i + 1}{n + 2}$$

(v) 从理论基础来看，MLE 基于频率学派观点，认为参数是未知但固定的量。它的目标是找到使得观测数据出现的概率最大的参数值。它只利用数据来估计参数，不引入额外的假设。BE 基于贝叶斯学派观点，认为参数是一个随机变量，有其自身的概率分布。贝叶斯估计通过结合数据和先验分布来估计参数，即通过更新先验信息得到后验分布，从后验分布中得到参数的估计值。从结果来看，MLE给出的是一个点估计，BE给出的则是一个分布。从计算复杂度来看，一般而言，MLE 计算量相比BE 更小。

Problem 3

1.

$$\begin{aligned}
 L(\omega) &= \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - f(x_i, \omega))^2}{2\sigma^2}\right) \\
 &\propto \exp\left(-\frac{\sum_{i=1}^N (y_i - f(x_i, \omega))^2}{2\sigma^2}\right) \\
 &= \exp\left(-\frac{E(\omega)}{\sigma^2}\right)
 \end{aligned}$$

命题得证

2.

$$\begin{aligned}
 p(\omega|\mathcal{X}, \mathcal{Y}, \sigma, \tau) &= L(\omega)p(\omega|\tau) \\
 &\propto \exp\left(-\frac{\sum_{i=1}^N (y_i - f(x_i, \omega))^2}{2\sigma^2} - \frac{\sum_{i=1}^M \omega_i^2}{2\tau^2}\right)
 \end{aligned}$$

因此在 $\lambda = \frac{\tau^2}{\sigma^2}$ 时，原命题成立

Problem 4

1. Fig. 1 绘制了不同 n 下 $a = 0.2, 0.5, 1.0, 2.0$ 的结果




Figure 1: 不同 n 和窗口大小 a 下Parzen 窗法模拟结果

2. 可以用数值积分方法代替积分计算，首先可以将二阶误差项拆成三项的和

$$\epsilon(p_n) = \int p_n(x)^2 - 2p_n(x)p(x) + p(x)^2 dx$$

使用数值积分方法可以求得，对于给定的区间 $[l, h]$ ，窗口宽度 a ，窗口将区间分为 M 段

$$\epsilon(p_n) \approx \sum_{i=1}^M (p_n(x_i)^2 - 2p_n(x_i)p(x_i) + p(x_i)^2)a$$

3. 如tab.1 tab.2所示，随着 n 的增加，估计会更佳准确，因此 $\epsilon(p_n)$ 的期望和方差都会减小如果 n 比较大，随着 a 的减小，通常来说 $p_n(x)$ 在细节上会更接近真实的 $p(x)$ ，偏差减小， $\epsilon(p_n)$ 的期望和方差随之减小，如果 n 比较小，则随着 a 的减小，数据波动性会增强， $\epsilon(p_n)$ 的期望和方差随之增大

n	$a = 0.2$	$a = 0.5$	$a = 1$	$a = 2$
5	0.9287	0.3573	0.1462	0.0601
10	0.4824	0.1739	0.0799	0.0276
50	0.0973	0.0371	0.0147	0.0082
100	0.0450	0.0171	0.0074	0.0048
1000	0.0047	0.0018	0.0009	0.0024
10000	0.0005	0.0002	0.0003	0.0022

Table 1: Mean Error for different n and a

n	$a = 0.2$	$a = 0.5$	$a = 1$	$a = 2$
5	0.0333	0.0156	0.0038	0.0014
10	0.0119	0.0031	0.0014	0.0005
50	0.0008	0.0002	0.0001	0.00003
100	0.0001	0.00004	0.00001	0.00001
1000	0.000001	0.0000004	0.0000003	0.0000006
10000	0.00000001	0.000000004	0.00000001	0.00000005

Table 2: Variance for different n and a

4. 从上面的模拟结果来看，如果 n 比较大，则应该选取较小的 a ，反之，则 a 不宜过小，应该适当控制每个窗口内的样本量
5. Fig.2 展示了使用不同宽度高斯窗的模拟结果，Tab.3, Tab.4 展示了二阶偏差的均值和方差，所得到的结论与使用矩形窗函数一致。对比矩形窗和高斯窗的使用，可以看到在 n 比较小的时候，高斯窗模拟估计出来的函数平滑性更好，并且二阶偏差的均值和方差整体要小于矩形窗，当样本量较大时，二者性能基本一致，都能比较好的估计目标函数




Figure 2: 不同 n 和窗口大小 a 下高斯窗模拟结果

n	$a = 0.2$	$a = 0.5$	$a = 1$	$a = 2$
5	0.2291	0.0680	0.0263	0.0494
10	0.1132	0.0318	0.0216	0.0496
50	0.0240	0.0082	0.0125	0.0471
100	0.0110	0.0048	0.0112	0.0473
1000	0.0012	0.0015	0.0105	0.0472
10000	0.0001	0.0012	0.0105	0.0472

Table 3: Mean Error for different n and a

n	$a = 0.2$	$a = 0.5$	$a = 1$	$a = 2$
5	0.0102	0.0021	0.0006	0.0001
10	0.0035	0.0005	0.0002	0.0001
50	0.0002	0.00003	0.00002	0.000007
100	0.00003	0.000009	0.00001	0.000004
1000	0.0000003	0.0000005	0.000001	0.0000005
10000	0.000000005	0.00000004	0.00000009	0.00000003

Table 4: Variance for different n and a