

模式识别大作业研究报告：面向AI 生成内容检测

刘泽禹、周韧平

September 20, 2026

1 研究背景及意义

随着人工智能技术的快速发展，生成对抗网络（GANs）、扩散模型（Diffusions）等生成模型在图像、视频、音频等领域的应用日益广泛。这些技术虽然带来了便利，也引发了新的问题，特别是“伪造”图像的生成与传播，给社会和安全领域带来了巨大的挑战。AI生成的图像（例如深度伪造或Deepfake图像）已被广泛应用于虚假新闻、社交媒体诈骗、身份盗用等非法活动，严重影响了信息的可信度和网络安全。

CIFAKE [BL24]是一个专门用于检测AI生成图像的数据集¹，通过收集和标注AI生成的图像与真实图像，提供了一个重要的研究基础。AI生成的图像具有复杂性与隐蔽性，传统的图像识别技术在检测此类图像时存在一定难度。因此，研究如何有效检测AI生成的合成图像具有重要的学术和现实意义，不仅有助于图像处理技术的进一步发展，也为网络安全提供有力的支持。




Figure 1: CIFAKE 数据集示例

2 方法

受到当今深度学习领域预训练-微调的范式启发，我们从大规模网络级别数据预训练的ViT 模型 [KDW+21] 出发。通过有监督微调整个网络与一个线性分类层的方式进行训练。在输入端，模型首先通过大核卷积将图片处理为 16×16 的图像块，随后经过多个多头注意力层提取特征，最终由一个线性分类器判断图片是否为深度伪造。模型结构如图所示²。

3 实验

3.1 实验设置与主要结果

实验在CIFAKE 数据集上进行，我们微调ImageNet-21k 预训练的ViT-Base 模型，使用学习率为 $1e-4$ 的AdamW优化器、批次大小为32训练5个epoch，最优分类准确率为98.25%。

3.2 消融实验

我们对于方法中的不同设计进行消融以验证其有效性。

预训练权重的影响 预训练已经成为了当今深度学习领域的重要范式。在大规模网络级别数据集上预训练的模型通常能够呈现出强大的泛化性和通用性，作为“基础模型”应用于各种下游任务中。因




Figure 2: ViT 模型架构，图片源自ViT 模型论文

Table 1: 骨干网络预训练权重的影响

	预训练	非预训练
准确率(%)	98.25	90.93

此，我们希望在深度伪造检测这一任务中验证预训练的影响，即对骨干网络是否经过预训练的影响进行探究。我们固定网络结构不变，分别加载了从ImageNet-21k [DDS⁺09] 上初始化的预训练权重以及随机初始化的权重进行实验。比较结果如表 1 所示。结果表明，由大规模数据预训练后的骨干网络能够提取更好的图像特征，更加便于后续分类器进行学习。

预训练范式的影响 在计算机视觉领域，多种从不同角度出发的预训练范式在不同任务中通常会起到不同的影响：有的范式更适合包含宏观语义信息的任务、另一些范式则适用于细粒度任务。因此，我们希望典型的预训练范式进行比较，探究不同范式在深度伪造检测任务中的适用性。我们固定了网络结构，并在此基础上选取了有监督学习的ViT-Base¹，视觉自监督学习的DINOv2-Base [ODM⁺23]²，以及视觉-语言对比学习的SigLIP-Base [ZMKB23]³ 的预训练权重进行比较。比较结果如表 2 所示。结果表明，在深度伪造检测任务中，有监督学习得到的特征最为有效，而在其他下游任务重广泛应用的视觉自监督预训练模型DINOv2 反而有较大的性能差异。

Table 2: 预训练范式的影响

预训练范式	有监督学习	视觉自监督学习	视觉-语言监督学习
模型	ViT-Base	DINOv2-Base	SigLIP-Base
准确率(%)	98.25	93.05	96.67

模型结构的影响 在骨干网络方面，卷积神经网络与Transformer 网络的比较一直是学术界的重要议题。因此，我们选取了与ViT-Base 大体相当量级的典型卷积神经网络模型ResNet-101 [HZRS16] 进行比较，以验证网络结构对于深度伪造检测结果的影响。比较结果如表 3 所示。结果表明，在深度伪造检测中，卷积神经网络与Transformer 网络基本上可以达到相似的效果，并不存在明显的性能差异。

深度学习方法与传统机器学习方法的比较 深度学习与传统机器学习的比较是许多任务当中的常见议题。因此，我们也对这一点进行消融比较。我们抽取了预训练骨干网络提取的图像特征，并在该特征的基础上实现了SVM、逻辑回归、随机森林以及KMeans 几种常见的传统机器学习方法，并与我们的方法进行比较。比较结果如表 4 所示。结果表明，一些传统方法也能在深度网络提取的特征基础上达

¹<https://huggingface.co/google/vit-base-patch16-224>

²<https://huggingface.co/facebook/dinov2-base>

³<https://huggingface.co/google/siglip-base-patch16-224>

Table 3: 骨干网络结构的影响

模型架构	Transformer架构	CNN架构
模型 准确率(%)	ViT-Base 98.25	ResNet-101 97.98

Table 4: 传统机器学习方法

方法	ViT-Base finetune	SVM	Logistic Regression	Random Forest	Kmeans
准确率(%)	98.25	95.545	93.425	88.670	50.565

到较好的性能，如SVM、逻辑回归等。而Kmeans 为代表的方法表达能力则有所不足，即便是与深度网络特征结合分类结果也有所欠缺。

References

- [BL24] Jordan J Bird and Ahmad Lotfi. Cifake: Image classification and explainable identification of ai-generated synthetic images. *IEEE Access*, 2024.
- [DDS⁺09] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*, pages 248–255. Ieee, 2009.
- [HZRS16] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [KDW⁺21] Alexander Kolesnikov, Alexey Dosovitskiy, Dirk Weissenborn, Georg Heigold, Jakob Uszkoreit, Lucas Beyer, Matthias Minderer, Mostafa Dehghani, Neil Houlsby, Sylvain Gelly, Thomas Unterthiner, and Xiaohua Zhai. An image is worth 16x16 words: Transformers for image recognition at scale. 2021.
- [ODM⁺23] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- [ZMKB23] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11975–11986, 2023.