

【统计学方法及其应用】假设检验章节作业

假设检验 功效函数 t检验 非参数检验 贝叶斯因子

注意：

1. 计算和证明题要写出推导的详细过程，只写答案要扣一半的分数
2. 尽量上传pdf文件，如果手写答案则扫描成pdf文件
3. 本次作业截止日期为**2025年12月23日**
4. 作业中附上运行结果截图，与源代码一并打包上传
5. 本次作业严禁抄袭，包括往年的作业，代码和报告部分应独立完成！

背景

数据污染指原始数据因测量或其他因素而失真、缺失或受到损害，影响其完整性和真实性。数据原本应客观地反映现实，真实的数据有助于正确呈现事物的各个方面特征。举例来说，一个人的身高、体重和血压等数据可以反映其健康状况。数据污染会扭曲事物的真实面貌，削弱数据的可信度，甚至可能导致错误结论的产生。

数据污染可能对假设检验的结论造成负面的影响，若真实数据与检验方法假设的总体具有明显的差别，从而不满足检验的基本假设，那么会对假设检验的功效和以及结论的正确性造成负面的影响，甚至可能会产生严重的后果。

在本次作业中，我们希望探究数据污染在进行假设检验时所能够造成的影响，从而体会如何更好地应对可能出现的污染，并了解进行假设检验前所需要进行的工作。

方法

数据污染模型

在本次作业中我们探究重尾、轻尾以及离群值三种数据污染问题对假设检验造成的影响。具体而言，我们通过正态分布和其他分布的混合来构成数据污染模型，从而模拟不同类型的数据污染。相比较于正态分布，T分布尾部更加厚重，Laplace分布尾部更加平坦，因此可以通过将这两种分布与正态分布混合来模拟重尾和轻尾污染。而对于离群值，我们根据 3σ 原则，在采样时额外加入区间 $(\mu - 3\sigma, \mu + 3\sigma)$ 以外的数据点，从而模拟在正态分布的数据中加入离群值污染。

为模拟不同程度的数据污染，我们通过控制来自正态分布与其他分布的数据占比，生成具有不同污染程度的混合数据。混合方法如下所示：

1. 给定总样本量 n 和污染比例 λ ，确定两部分数据的样本量：
 - 从正态分布 $N(\mu, \sigma^2)$ 中采样 $(1 - \lambda) \cdot n$ 个样本；
 - 从污染分布（如 t 分布、拉普拉斯分布、离群值）中采样 $\lambda \cdot n$ 个样本。
2. 将上述两部分样本组合为一个数据集，表示为混合数据 X 。

混合方法的数学形式如下所示：

$$X = \{x_i \sim g(x) \text{ for } i = 1, \dots, (1 - \lambda)n\} \cup \{x_j \sim f(x) \text{ for } j = 1, \dots, \lambda n\},$$

其中：

- $g(x)$ 表示正态分布的概率密度函数；
- $f(x)$ 表示污染分布（例如重尾分布或轻尾分布）的概率密度函数。

功效函数的仿真

在满足检验对统计显著性要求的前提下，功效函数决定了一个检验犯第二类错误的概率。我们总是希望寻找功效更大的检验，从而可以通过比较功效函数来比较两个检验的方法。具体来说，如果功效函数的理论形式很难获得，我们可以通过模拟的方式。设检验为 T ，总体为 F ，参数为 θ ，模拟功效函数 $\beta(T, F, \theta)$ ：

1. 确定检验 T 的拒绝域。通常拒绝域有 $R = x : W(x) > c_\alpha$ 的形式，其中 c_α 是一个常数，由预期的统计显著性水平 α 确定。如果检验统计量就是 p-value 的话，那么拒绝域可以通过 p-value 确定。
2. 对于某个特定的参数 θ_0 ，用随机数生成器生成 n 个观测样本 $x_1, \dots, x_n$ 。对于每个观测样本 x_i ，计算检验统计量 $w_i = W(x_i)$ 并判断 x_i 是否属于拒绝域 R 。设 n 个样本中有 n' 个样本处于拒绝域内，则该处功效函数值为

$$\beta(T, F, \theta_0) \approx \frac{n'}{n}$$

3. 对于集合 Θ 中的每一个 θ 应用步骤2，其中集合 Θ 是希望模拟功效函数的所有参数的集合

用上述方法，我们可以比较四种检验（t-检验、符号检验、贝叶斯检验和Wilcoxon符号秩检验）在不同总体（T分布，拉普拉斯分布）与正态总体混合污染下的功效

作业

令假设检验问题为

$$H_0 : m = m_0 \text{ versus } H_1 : m \neq m_0$$

其中 m 是总体 F 的中位数， $m_0 = 0$ 是我们对中位数的猜测。令 $\mathcal{F} = \{N, T, L\}$ 为我们关心的总体， $\mathcal{H} = \{T, S, W, B\}$ 为我们关心的检验。

$N \sim Normal(m, 1)$ 表示正态分布， $T \sim t(\nu)$ 表示T分布， $L \sim Laplace(m, 1)$ 表示拉普拉斯分布。 T 表示t检验， S 表示符号检验， W 表示Wilcoxon符号秩检验， B 表示贝叶斯检验

1. 建立数据污染模型。

编写仿真程序，自行决定样本容量和T分布的自由度，绘制Q-Q图，观察重尾、轻尾和离群值污染在占比0-100%时对数据的正态性造成的影响；（注：请在生成仿真数据前设置好随机种子，随机种子设置为学号的后四位，保证实验和分析流程可重复）

2. 研究t-检验贝叶斯因子与p-value的关系。

假设选取先验参数 $\alpha = \beta = \xi = \kappa = 1$ ，令样本容量固定为20，方差固定为1，均值从0到2，步长0.1，改变均值。编写程序，在每组参数下随机产生200组数据，计算t-检验的 $p - value$ 和贝叶斯因子，并给出在 $p - value$ 为0.05时所对应的贝叶斯因子的大小，从而确定贝叶斯检验的拒绝域；

3. 仿真正态总体的功效。

对于正态总体，假定拒绝域就是 $p - value$ 小于0.05。选择适合的 n ，编写程序，对每个检验 $T \in \mathcal{T}$ 模拟功效函数 $\beta(T, F, \theta)$ ，自行决定有代表性的 θ 的取值，将四个检验 $\mathcal{H}$ 的功效函数画在一张图内，包含四条曲线。比较图中结果，对四个检验 $\mathcal{H}$ 的表现给出一个排序；

4. 研究重尾/轻尾污染对功效的影响。

在数据中加入重尾和轻尾污染，T分布的自由度参数 ν 分别选取1、5、10、15，在污染数据占比0%，25%，75%，100%的情况下各绘制一张图，每张图包含四种不同检验的功效函数，观察重尾污染和轻尾污染对检验功效的影响；

5. 研究离群值污染对功效的影响。

在数据中加入离群值污染，在污染数据占比0%，5%，10%，15%，20%，25%的情况下各绘制一张图，每张图包含四种不同检验的功效函数，观察离群值对检验功效的影响；

6. 研究数据污染对显著性水平的影响。

在前述题目中，我们主要研究了数据污染对功效的影响。本题将进一步考察数据污染对检验的第一类错误概率的影响。

(a) 在无污染情况下（污染比例 $\lambda = 0$ ），通过模拟的方法验证三种检验（t检验、符号检验、Wilcoxon符号秩检验）在正态总体下是否能够保持约0.05的显著性水平。自行选择合适的模拟次数（例如2000或5000）。

(b) 研究重尾污染对显著性水平的影响：令污染分布为自由度 $\nu \in \{1, 5\}$ 的t分布，污染比例为

$$\lambda \in \{0\%, 10\%, 20\%, 30\%, 40\%, 50\%\}.$$

对每一个 (ν, λ) 组合，通过模拟估计三种检验的实际Type I Error，并绘制随污染比例变化的折线图（三条曲线）。

(c) 研究轻尾污染对显著性水平的影响：令污染分布为拉普拉斯分布，进行与(b)相同的分析。

对比上述结果，回答：

- 哪些检验对显著性水平最敏感？
- 哪些检验在数据污染下仍能较好维持0.05的Type I Error？
- 在实际应用中，这些发现如何帮助我们选择更鲁棒的假设检验方法？

7. 请总结何种情况是四种检验 $\mathcal{H} = \{T, S, W, B\}$ 分别最适合使用的场景。体会滥用正态分布、t分布的假设将会造成怎样的误导效应（实际上这种滥用有时还会造成严重的错误）。基于以上体会，说明在应用一个检验之前我们需要做怎样的工作？